note doc Simple online and realtime Tracking

Idée du papier : la qualité du detecteur compte ⊕ que la sophistication du tracker

Idée général : Tracking-by-détect° : à chaque image un detecteur donne des boîte, et le tracker doit les relier d'une image à l'autre pour garder l'identité d'un objet :

schéma

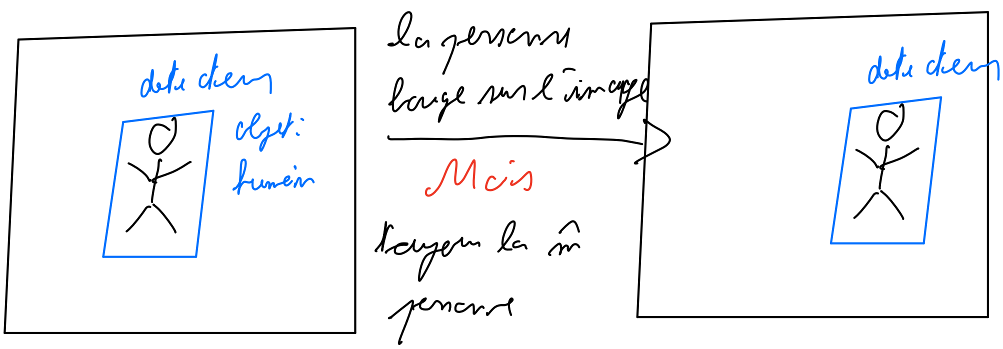

Contexte général

① Donc : MOT (suivi multi-objet) est vue comme un pb d'associat° de données

② On utilise le terme "online tracker" : CAD que le tracker utilise : Seulement l'image précédente et l'image courante.

Jamais le futur

les méthode qui utilise le futur sont de méthode dite "batch"

③ Temps réel → l'obj final sont les voiture / robot etc

④ On parle de la Philosophie "rasoir d'Occam"

↳ - On utilise seulement la posit° et la taille des boîte pour le tracking

- On utilise Pas : - l'apparence (couleur, descripteur visuel)
  - ré-identificat°
- Pas de gest° explicite des occlusion

Pas évident à comprendre donc schéma :

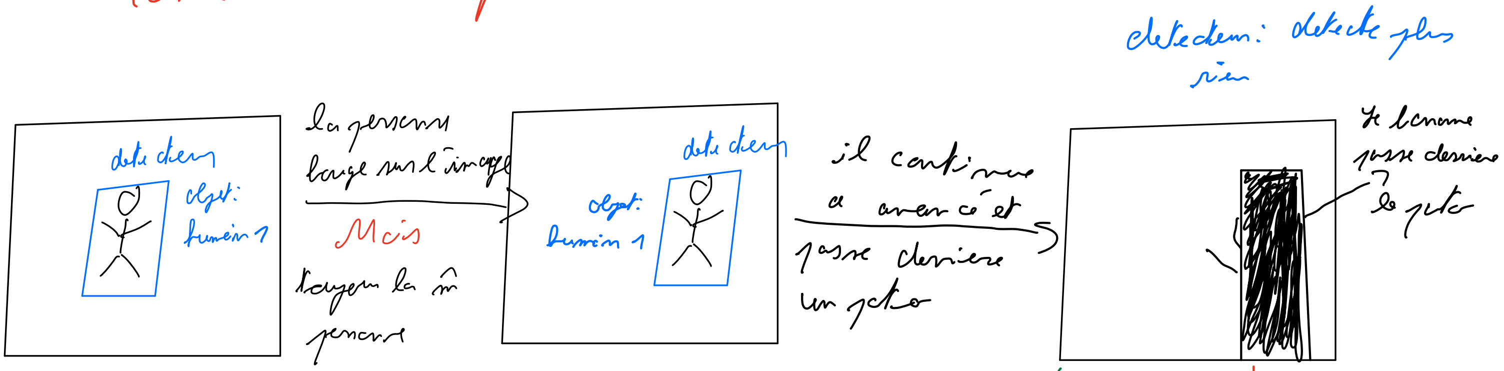
détecteur
objet: humain 1
la personne bouge sur l'image
Mais toujours la même personne
détecteur
objet: humain 1
il continue à avancer et passe derrière un poteau
détecteur: détecte plus rien
L'homme passe derrière le poteau

2 cas possible

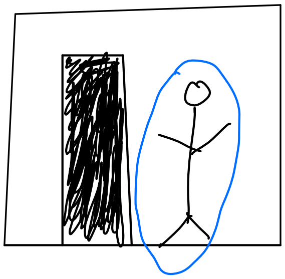

Le détecteur comprend que c'est le même objet que avant même si il a disparu

✓ bien

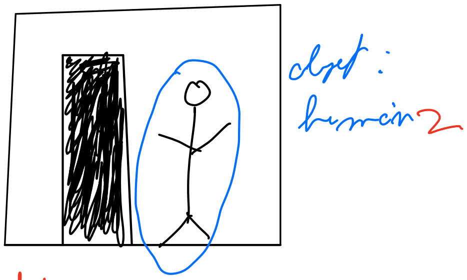

Le détecteur a pas compris que c'était le même objet que avant et dit que c'est un autre objet

✗ Pas cool

d'après papier, SORT gère les occlusions très courte mais pas les longues -> normal car sinon trop de calcul prédictif qui prend du temps donc pas de l'applicat° en temps réel -> nul

La pipeline : en 4 partie

① Detection :

lors de données avec plusieurs classe
↑

⊖ Ils utilisent Faster R-CNN -> Pré-entraîné sur Pascal Voc

↓ ↓

garde seulement la classe "Personne" avec proba > 50%

c'est quoi un "Faster R-CNN"

↳ donne 3 info :
- une boîte -> où est l'objet
- une classe -> personne, voiture etc
- score de confiance

lien avec le projet -> prendre d'autre classe que "personne", pour la vision d'un robot, peut être prendre un seuil ⊕ bas ?

pcq si seuil trop haut -> FN
↓
dangereux

Dans le papier, ils passe de detecteur ACF a FRCNN, leur MOTA passe de 15,1 à 34. (Dans l'abstract, ils parlent d'augmentat° jusqu'à 78,9 %, vient d'ici)

MOTA -> métrique pr noter un tracker multi objet

↳ $1 - \frac{FN + FP + IDSW}{GT}$ IDSW -> le nbr de fois où un objet change d'identité

② Modèle d'état et prédiction (Kalman)

⊖ chaque cible décrite par :

$$x = [\underbrace{u, v}_{\text{Centre de la boîte en pixel}}, s, r, \underbrace{\dot{u}, \dot{v}, \dot{s}}]^T$$

s : échelle, cad l'aire de la boîte

r : rapport d'aspect supposé constant d'où l'absence de $\dot{r}$

$\dot{u}, \dot{v}, \dot{s}$: dérivé, ce sont des vitesses

NB : modèle de mouvement à vitesse constante, linéaire, indépendant des autres objets et du mouvement de la caméra

si détect° associé à la cible -> la boîte détectée sert de mesure p la correct° de Kalman

Sinon, seulement une prédict°, sans correction

3 - Associat° (algo hongrois)

1 - On prédit la boîte de chaque piste ds l'image courante

2 - On construit une matrice de coût de taille pistes x détect°, avec la distance IoU (en pratique $1 - IOU$).

3 - L'algorithme hongrois résout de façon optimal globalement, et non de façon gloutonne.

4 - Toute affectat° avec une IoU inférieure à IoU_{min} est rejetée.

5 - l'IoU gère les occlusion courte) -> bonus

4) Création et suppression des pistes

- Créat° : détect° qui n'a été associé à aucune piste devient une nouvelle piste.
  vitesse initialisé à 0 avec grande cov car vitesse inconnue
  ↳ il y a une sorte de "période probatoire" -> les pistes doivent être confirmée par plusieurs détect°, pour éviter les Faux positif
- Suppression : Une piste est supprimé si elle n'est pas détectée pendant T_{lost} images
  T_{lost} = 1
  ↳ Pourquoi ? -> modèle à vitesse constante prédit mal sur la durée
  ↳ ré-identificat° est hors périmètre du papier.

Conséquence

un objet qui réapparait, reçoit une nouvelle identité.

Métrique a connaitre :

MOTA -> précision global du tracking

MOTP -> précision de localisat° des boites

FAF -> fausses alarmes par images

MT / ML -> trop suivie ⊕ de 80% du temps / perdu ⊕ de 80% du temps

FP / FN -> faux positif / faux negatif

IDSW -> changement d'identité

Frag -> trop fragmenté par des détect° manquée

résultat du papier : -> MOTA a 33,4 , le meilleur tracker online, au même niveau que NOMT (33,7) qui est bcp ⊕ complexe

-> le ⊖ de faux positif et le meilleur ML

-> 260 Hz sur un seul CPU, soit 20 ⊗ ⊕ rapide que les concur

⚠ important

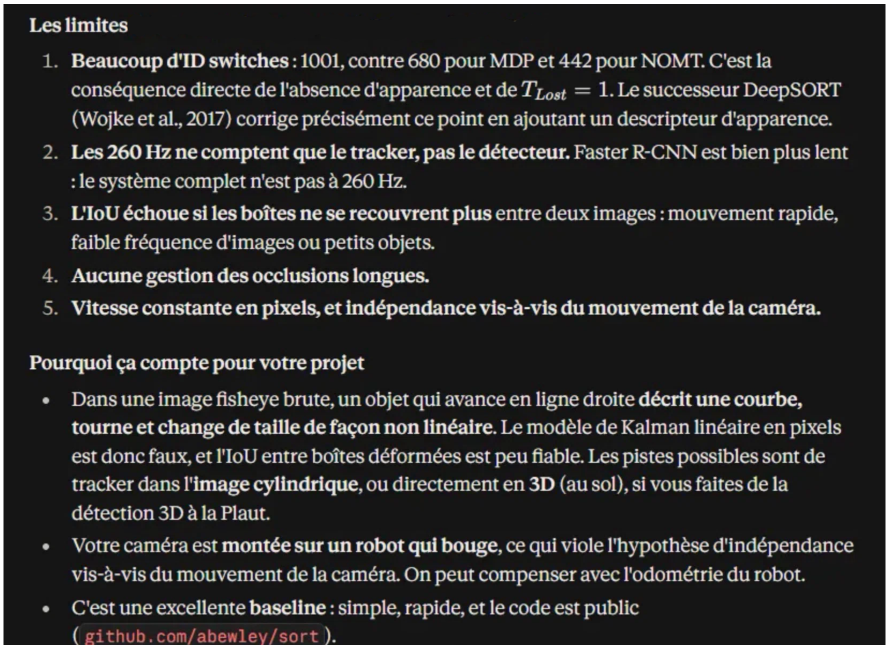

Les limites

1. **Beaucoup d'ID switches :** 1001, contre 680 pour MDP et 442 pour NOMT. C'est la conséquence directe de l'absence d'apparence et de $T_{Lost} = 1$. Le successeur DeepSORT (Wojke et al., 2017) corrige précisément ce point en ajoutant un descripteur d'apparence.
2. **Les 260 Hz ne comptent que le tracker, pas le détecteur.** Faster R-CNN est bien plus lent : le système complet n'est pas à 260 Hz.
3. **L'IoU échoue si les boîtes ne se recouvrent plus** entre deux images : mouvement rapide, faible fréquence d'images ou petits objets.
4. **Aucune gestion des occlusions longues.**
5. **Vitesse constante en pixels, et indépendance vis-à-vis du mouvement de la caméra.**

Pourquoi ça compte pour votre projet

- Dans une image fisheye brute, un objet qui avance en ligne droite **décrit une courbe, tourne et change de taille de façon non linéaire.** Le modèle de Kalman linéaire en pixels est donc faux, et l'IoU entre boîtes déformées est peu fiable. Les pistes possibles sont de tracker dans l'**image cylindrique**, ou directement en **3D** (au sol), si vous faites de la détection 3D à la Plaut.
- Votre caméra est **montée sur un robot qui bouge**, ce qui viole l'hypothèse d'indépendance vis-à-vis du mouvement de la caméra. On peut compenser avec l'odométrie du robot.
- C'est une excellente **baseline** : simple, rapide, et le code est public (`github.com/abewley/sort`).