Perception visuelle par caméras fisheye embarquées

Sala Raphaël,

DATE

Résumé

Les caméras fisheye offrent un champ de vision étendu. Leur géométrie de projection, différente de celle des caméras perspectives, complique toutefois l'utilisation directe des méthodes classiques de vision. Ce projet étudie la calibration de ces capteurs et l'influence de différentes représentations de l'image sur deux tâches complémentaires : la détection et le suivi de personnes dans un flux vidéo, et l'estimation d'une carte de profondeur dense à partir d'un banc stéréo fisheye. À terme, leur association vise à localiser les personnes suivies dans le repère du robot. Ce rapport présente les fondements géométriques, les approches retenues dans la littérature et les critères envisagés pour leur évaluation.

le sommaire est juste là pour vérifier la pagination et la structure, il sera retiré dans le rapport final.

Table des matières

1 Introduction **1**

2 Prétraitements (3 pages) **2**

3 Détection et suivi (4 pages) **3**

4 Banc stéréo fisheye et estimation dense (4 pages) **3**

5 Projet **4**

1 Introduction

Les caméras fisheye occupent une place importante en vision par ordinateur dès qu'un large champ de vue est recherché. On les rencontre en robotique, en surveillance, en imagerie médicale, en réalité virtuelle et dans de nombreux autres domaines REF. Leur intérêt principal est de capturer un champ de vision beaucoup plus large qu'une caméra perspective classique. Toutefois les objets observés loin de l'axe optique apparaissent fortement déformés et les méthodes de vision classiques, souvent conçues pour des images rectilignes, ne s'appliquent pas directement.

Je réfléchis toujours à insérer un schema explicatif + voir si on aura besoin des ces notations. Je laisse tel quel pour l'instant. Pour décrire cette différence, on considère un point 3D exprimé dans le repère de la caméra de coordonnées $X_c = (X, Y, Z)^\top$. La direction de ce point peut être décrite par deux angles : l'angle polaire θ qui mesure son écart à l'axe optique et l'azimut φ qui indique sa direction autour de cet axe. Dans un modèle fisheye central, l'idée essentielle est que l'on ne projette pas directement le point 3D sur un plan image comme dans le modèle perspective classique. On commence d'abord par relier l'angle θ à une distance radiale dans l'image, notée $q(\theta)$. Cette fonction q décrit donc la manière dont une direction de l'espace est reportée dans l'image. Une fois cette distance radiale obtenue, on la répartit selon la direction angulaire φ, puis on convertit la position obtenue en coordonnées pixels grâce aux paramètres intrinsèques de la caméra, en particulier les focales f_x, f_y et le point principal (c_x, c_y). Ainsi, le rôle de q est central, c'est elle qui détermine comment les

écarts angulaires dans la scène se traduisent en distances dans l'image et donc la nature même de la déformation fisheye.

Plusieurs modèles de projection se distinguent par la loi radiale $q(\theta)$ qui associe à chaque direction de visée une position dans l'image (figure 1). Le modèle rectiligne utilise $q(\theta) = \tan\theta$ et permet que les droites de l'espace restent des droites dans l'image. En revanche, cette fonction diverge lorsque θ approche 90°, ce qui empêche de représenter sur un seul plan perspective un champ atteignant 180°. Les projections fisheye classiques répartissent autrement les directions observées. Le modèle équidistant fait correspondre des écarts angulaires égaux à des écarts radiaux égaux, tandis que le modèle équisolide conserve les rapports d'angles solides sous forme de rapports d'aires dans l'image. Le modèle stéréographique préserve localement les angles, alors que la projection orthographique correspond à la projection d'un hémisphère sur un plan [**schneider2009**, 1]. Ces propriétés ont des conséquences sur la déformation des objets et la distribution des détails dans l'image. Les domaines de validité diffèrent également, par exemple la loi orthographique $q(\theta) = \sin\theta$ cesse d'être injective au-delà de 90°.

Ces modèles sont toutefois des descriptions idéales. La projection d'une optique réelle s'en écarte en raison des imperfections de fabrication et d'alignement. La calibration consiste alors à estimer un modèle capable de reproduire les positions effectivement mesurées dans l'image. Kannala et Brandt proposent notamment une loi radiale polynomiale qui généralise la projection équidistante et dont les coefficients sont ajustés à partir d'observations de calibration [2]. D'autres familles reposent sur une construction géométrique différente. Le modèle unifié de Mei et Rives fait intervenir une projection sur une sphère [3], tandis que le modèle Double Sphere utilise deux sphères et permet un calcul efficace de la projection inverse [4]. Aucun modèle n'est optimal pour toutes les optiques. Leur pertinence se juge notamment par la précision de reprojection, le domaine angulaire couvert et le coût des transformations. Une calibration fiable est ainsi nécessaire pour relier les pixels aux directions de l'espace et pour réaliser ensuite des reprojections ou des traitements stéréoscopiques cohérents [**schneider2009**, 1]. J'essaierai de m'y intéresser plus pour expliquer pourquoi on choisit l'un oplutôt que l'autre dans la section Projet. Ca dépendra de commnent la calibration banc stéréo est présenté afin de pas faire redondant ou de trop technique.

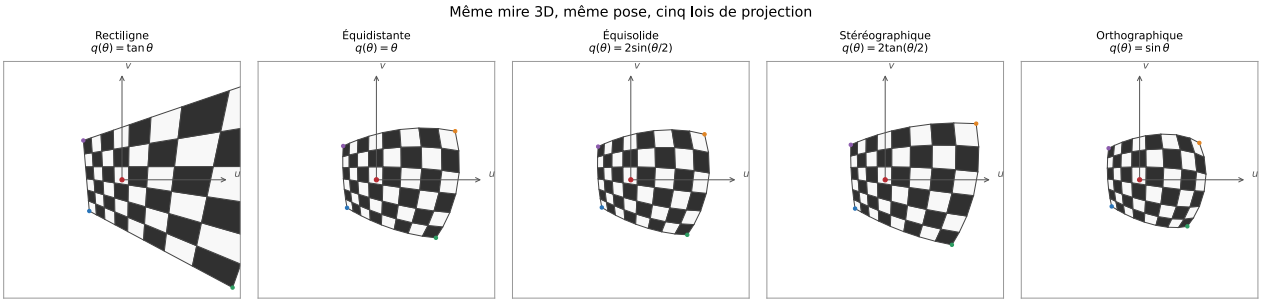


FIGURE 1 – Comparaison de cinq lois de projection appliquées à un même damier en 3D. La fonction $q(\theta)$ est indiquée pour chaque modèle. TODO : grossir texte image

La suite de ce rapport s'organise autour de quatre parties. Nous étudions d'abord les principaux prétraitements des images fisheye, en particulier les reprojections cylindrique et équirectangulaire, ainsi que leurs limites. Nous présentons ensuite les approches de détection et de suivi de personnes, avant d'aborder la calibration d'un banc stéréo fisheye et les méthodes d'estimation de profondeur dense. Enfin, nous revenons sur les choix méthodologiques et les avancées du projet, avec pour objectif à terme de combiner le suivi et la profondeur afin de localiser les personnes dans l'espace.

2 Prétraitements (3 pages)

Principe du pré-traitement, justification et bref énumération des diffrentes méthodes avant de se concentrer sur cylindrique et ERP, analyse qualitative (car quantitative c'est pas vraiment possible je

crois)

Cylindrique

ERP images

3 Détection et suivi (4 pages)

Détection

Décrire brièvement la logique d'un détecteur préentraîné (YOLOv8 / YOLO11 ; RT-DETR [5] en comparaison si justifiée). Cout computationnel, vitesse, précision, classes disponibles, AP50, mAP50–95. Montrer les limites de la détection sur des images fisheye brutes et les améliorations obtenues par reprojection cylindrique ou ERP. Mentionner brièvement les alternatives (FishEye8K [6], WoodScape [7]) et leurs limites (données synthétiques, classes limitées, performances moindres). Montrer que la détection est un prérequis pour le suivi et la localisation 3D.

Tracking

Principe du tracking, filtre de Kalmann, occlusion,cout computationnel

Expliquer (brievement) les différentes approches/modèles la chronologie, les nouveautés, les performances **SORT** [8] (Kalman + IoU + affectation), **Deep SORT** [9] (apparence), **ByteTrack** [10] (détections de confiance basse), **BoT-SORT** [11] (mouvement/apparence). Puis deux publications spécialisées au *suivi fisheye* particulièrement utiles : **FORT** [12] et suivi de boîtes orientées **Lam (BMVC 2024)** [13].

4 Banc stéréo fisheye et estimation dense (4 pages)

Calibration relative et rectification

Présenter la chaîne : deux vues → poses calibrées → rectification épipolaire adaptée à la géométrie → correspondances. Une projection panoramique *seule* n'est pas équivalente à une rectification stéréo. Références à présenter dans un ordre historique lisible : Abraham–Förstner (2005) [14] ; Ohashi (2016/2017) [15, 16] ; Schneider (2016) [17]. Comme mise en perspective plus moderne, mentionner les stratégies de rectification d'**OmniVidar** [18] et de projection de Cassini dans **OmniStereo** [19]. Les méthodes multi-fisheye ne sont pas toutes transférables à deux caméras ; préciser le nombre et la disposition des capteurs des articles. **Figure requise :** deux centres de caméras, rayons vers un point 3D et plan/ligne épipolaire ; puis une paire réellement rectifiée avec lignes guides.

Cartes denses et évaluation

decrire ce que sont les cartes de profondeur, comment elles sont faites : creuses VS denses. On se concentre sur la derniere car [? ?]

Classique : **StereoSGBM** [20], puis modèles préentraînés de correspondance stéréo **RAFT-Stereo** [21], **FoundationStereo** [22] (et éventuellement **Fast-FoundationStereo**, 2026 [23]). En état de l'art stéréo panoramique, citer **OmniMVS** [24], **OmniVidar** [18], **OmniStereo** [19], **DFI-OmniStereo** [25] et **MDP-Omni** [26] en les situant selon leur rig et leur projection. **WideDepth** [27] est un benchmark pertinent pour une première validation ; ses images de test fisheye sont produites à partir de scans laser de scènes réelles : ne pas les confondre avec une séquence brute capturée par vos caméras. HELVIPAD [28] est utile pour les images ERP, mais provient d'un autre type de configuration (deux caméras omnidirectionnelles superposées).

5 Projet

Parler de notre projet en particulier, des différentes avancées. De la pipeline pour aborder la détection. Je pense le but final c'est d'arriver à traquer dans un espace 3d, un groupe de personnes qui marche et de reussir à savori où elles se trouvent. De manière détaillée ça serait :

Pour chaque personne détectée et suivie, remapper sa zone en coordonnées de la carte de profondeur, extraire une estimation robuste de distance (avec masque valide), reconstruire un point 3D et le transformer dans le repère robot. Le point 3D estimé sera un *point représentatif* et non une boîte 3D complète, sauf extension décidée explicitement. Une médiane des valeurs de profondeur dans une région centrale est une première approche pratique, mais peut être biaisée par le fond ; mentionner le besoin éventuel de segmentation ou d'un point d'appui pertinent. Les ID sont définis par le tracker, pas par la carte de profondeur. **Figure requise :** image avec bbox personne et ID, carte de profondeur correspondante, même ID associé à un point (X, Y, Z) dans le repère du robot.

Bibliographie citée dans ce plan

[1] S. Yogamani et al. "WoodScape : A Multi-Task, Multi-Camera Fisheye Dataset for Autonomous Driving". In : *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2019, p. 9308-9318. DOI : 10.1109/ICCV.2019.00940.

[2] J. Kannala et S. S. Brandt. "A Generic Camera Model and Calibration Method for Conventional, Wide-Angle, and Fish-Eye Lenses". In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 28.8 (2006), p. 1335-1340. DOI : 10.1109/TPAMI.2006.153.

[3] C. Mei et P. Rives. "Single View Point Omnidirectional Camera Calibration from Planar Grids". In : *IEEE International Conference on Robotics and Automation (ICRA)*. 2007. DOI : 10.1109/ROBOT.2007.364084.

[4] V. Usenko et al. "The Double Sphere Camera Model". In : *International Conference on 3D Vision (3DV)*. 2018, p. 552-560. DOI : 10.1109/3DV.2018.00069.

[5] Y. Zhao et al. "DETRs Beat YOLOs on Real-time Object Detection". In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, p. 16965-16974.

[6] E. Plaut. *Tutorial on Computer Vision with Fisheye Cameras*. URL : https://plaut.github.io/fisheye_tutorial/ (visité le 23/10/2026).

[7] P. Bourke. *Converting a fisheye image to panoramic, spherical and perspective projection*. URL : https://paulbourke.net/dome/fish2/ (visité le 23/10/2026).

[8] A. Bewley et al. "Simple Online and Realtime Tracking". In : *2016 IEEE International Conference on Image Processing (ICIP)*. 2016, p. 3464-3468. DOI : 10.1109/ICIP.2016.7533003.

[9] N. Wojke et al. "Simple Online and Realtime Tracking with a Deep Association Metric". In : *2017 IEEE International Conference on Image Processing (ICIP)*. 2017. DOI : 10.1109/ICIP.2017.8296962.

[10] Y. Zhang et al. "ByteTrack : Multi-Object Tracking by Associating Every Detection Box". In : *Proceedings of the European Conference on Computer Vision*. 2022, p. 1-21. DOI : 10.1007/978-3-031-20047-2_1.

[11] N. Aharon et al. *BoT-SORT : Robust Associations Multi-Pedestrian Tracking*. 2022. arXiv : 2206.14651.

[12] N. Odic et al. "FORT : Fisheye Online Realtime Tracking with an Improved Kalman Filter". In : *2023 IEEE 25th International Workshop on Multimedia Signal Processing (MMSP)*. 2023. DOI : 10.1109/MMSP59012.2023.10337701.

[13] J. Lam. "Motion Tracking with Rotated Bounding Boxes on Overhead Fisheye Imagery". In : *British Machine Vision Conference (BMVC)*. 2024.

[14] S. Abraham et W. Förstner. “Fish-eye-stereo calibration and epipolar rectification”. In : *ISPRS Journal of Photogrammetry and Remote Sensing* 59.5 (2005), p. 278-288. doi : 10.1016/j.isprsjprs.2005.03.001.

[15] A. Ohashi et al. “Fisheye stereo camera using equirectangular images”. In : *2016 11th France-Japan and 9th Europe-Asia Congress on Mechatronics / 17th International Conference on Research and Education in Mechatronics*. 2016, p. 284-289. doi : 10.1109/MECATRONICS.2016.7547156.

[16] A. Ohashi et al. “Fisheye stereo camera using equirectangular images”. In : *Journal of the Japan Society for Precision Engineering* 83.12 (2017), p. 1095-1100. doi : 10.2493/jjspe.83.1095.

[17] J. Schneider et al. “On the Accuracy of Dense Fisheye Stereo”. In : *IEEE Robotics and Automation Letters* 1.1 (2016), p. 227-234. doi : 10.1109/LRA.2016.2516509.

[18] S. Xie et al. “OmniVidar : Omnidirectional Depth Estimation From Multi-Fisheye Images”. In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, p. 21529-21538.

[19] J. Deng et al. “OmniStereo : Real-time Omnidireactional Depth Estimation with Multiview Fisheye Cameras”. In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2025, p. 1003-1012. doi : 10.1109/CVPR52734.2025.00102.

[20] H. Hirschmüller. “Stereo Processing by Semiglobal Matching and Mutual Information”. In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 30.2 (2008), p. 328-341. doi : 10.1109/TPAMI.2007.1166.

[21] L. Lipson et al. “RAFT-Stereo : Multilevel Recurrent Field Transforms for Stereo Matching”. In : *2021 International Conference on 3D Vision (3DV)*. 2021, p. 218-227. doi : 10.1109/3DV53792.2021.00032.

[22] B. Wen et al. “FoundationStereo : Zero-Shot Stereo Matching”. In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2025.

[23] B. Wen et al. “Fast-FoundationStereo : Real-Time Zero-Shot Stereo Matching”. In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2026, p. 7513-7524.

[24] C. Won et al. “OmniMVS : End-to-End Learning for Omnidirectional Stereo Matching”. In : *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2019.

[25] J. Endres et al. “Boosting Omnidirectional Stereo Matching with a Pre-trained Depth Foundation Model”. In : *IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. 2025. eprint : 2503.23502.

[26] E. Son et al. “MDP-Omni : Parameter-free Multimodal Depth Prior-based Sampling for Omnidirectional Stereo Matching”. In : *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2025, p. 26178-26187.

[27] I. Indyk et al. “WideDepth : Millimeter-Accurate Benchmark for Fisheye Depth Estimation”. In : *2026 IEEE International Conference on Robotics and Automation (ICRA)*. 2026, p. 17817-17824. doi : 10.1109/ICRA57385.2026.11696790.

[28] M. Zayene et al. “HELVIPAD : A Real-World Dataset for Omnidirectional Stereo Depth Estimation”. In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2025, p. 26975-26984.